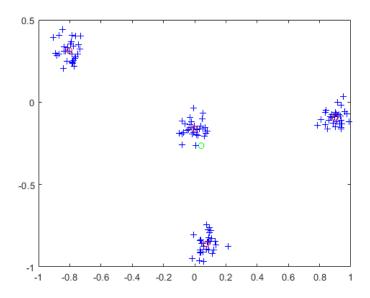
Sieci neuronowe – sprawozdanie nr 4

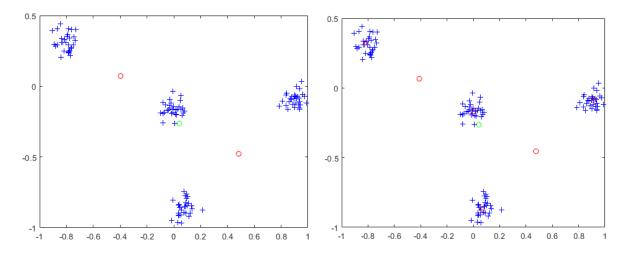
Zadanie 1.

Pierwszym zadaniem było wczytanie danych z kilku gotowych plików oraz dobrać ilość neuronów w sieci i po jej nauczeniu (uczenie konkurencyjne) wyznaczyć środki klas (klastrów) danych:

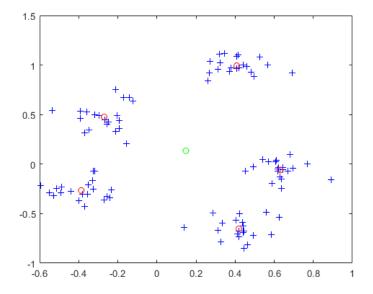
• dane1 – dwuwejściowe, 4 klastry = 4 neurony:



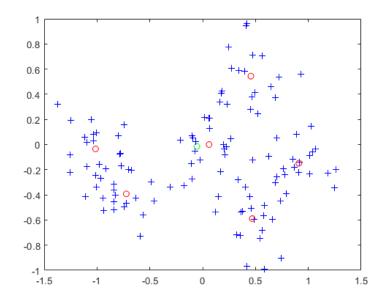
 przykład dla źle dobranej ilości neuronów (2 i 6) – niewłaściwy podział na klastry (zbyt mało lub zbyt dużo klastrów w stosunku do rozłożenia danych):



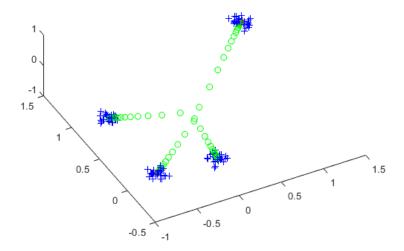
dane2 – dane dwuwejściowe, 5 klastrów = 5 neuronów:



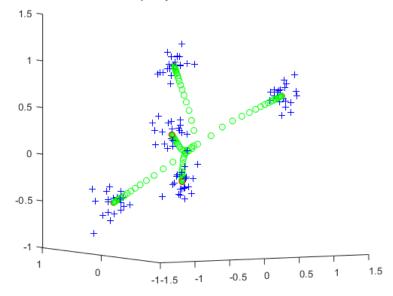
• dane3 – dane dwuwejściowe, 6 klastrów = 6 neuronów:



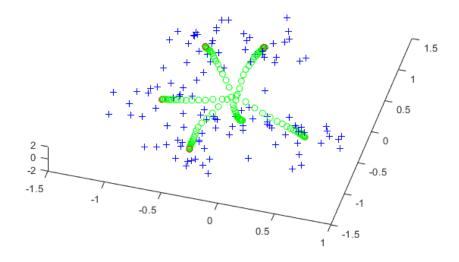
• dane3d1 – dane trzywejściowe, 4 klastry = 4 neurony:



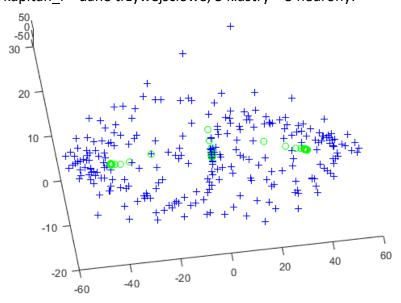
• dane3d2 – dane trzywejściowe, 5 klastrów = 5 neuronów:



• dane3d3 – dane trzywejściowe, 6 klastrów = 6 neuronów:



• kapitan_i – dane trzywejściowe, 3 klastry = 3 neurony:



Zadanie 2.

Drugim zadaniem było samodzielne opracowanie skryptu, za pomocą którego wczytywane zostaną dane i podana ilość klastrów, a następnie zostaną wyznaczone środki klastrów z wykorzystaniem uczenia konkurencyjnego.

```
load dane2.txt
in = dane2';
neurons = 5; % number of clusters = neurons
lr = 0.2; % learning rate
epochs = 150;
% setting weights of neurons
w = [];
for i = 1:neurons
    w = [w; rand(1,2)];
end
w = w';
plot(w(1,:),w(2,:),'go') % neurons starting points
hold on
% learning the neurons
for x=1:epochs
    for k=1:length(in)
        d = []; % vector of distances of the sample from neurons
        for j = 1:neurons
            d = [d norm(in(:,k)-w(:,j))];
        [winner, ind] = min(d); % the winner neuron (with minimal
distance from the sample)
        w(:,ind) = w(:,ind) + lr * (in(:,k) - w(:,ind)); % new weights
for the winner
    end
end
% learnt neurons
plot(in(1,:),in(2,:),'b+', w(1,:),w(2,:),'ro')
```

Wykres wynikowy – na zielono zaznaczono neurony przed uczeniem, a na czerwono – po uczeniu. Widać, że neurony podzieliły zbiór danych wejściowych na 5 klastrów.

